UNIVERSITÉ ABDELMALEK ESSAÂDI
FACULTÉ DES SCIENCES ET TECHNIQUES DE TANGER
FSTT – TANGER

MASTER INTELLIGENCE ARTIFICIELLE ET SCIENCES DES DONNÉES

Module : Espaces de données fédérés

RAPPORT DE TRAVAUX PRATIQUES

Conception d'un espace de données fédéré

Stockage, traitement, gouvernance et confidentialité des données

Étude de cas : qualité de l'air et admissions hospitalières à Tanger

Encadré par
Prof. Ouafae Baida

Réalisé par
Mahmoud EL GHARIB
Ezzoubair ZARQI
Mohamed EL ATTAR

Année universitaire 2026–2027

Table des matières

Résumé 1

1 Introduction générale 2

1.1 Contexte et problématique . . . 2

1.2 Objectifs . . . 2

1.3 Jeu de données et hypothèses . . . 2

2 TP 1 — Stockage fédéré et analyses locales 4

2.1 Principe et réalisation . . . 4

2.2 Réponses aux questions . . . 4

3 TP 2 — Communication entre organisations avec API REST 6

3.1 Principe et réalisation . . . 6

3.2 Résultats et réponses aux questions . . . 7

4 TP 3 — Calcul local, contrôle d'accès et analyse fédérée 9

4.1 Principe et réalisation . . . 9

4.2 Résultats et réponses aux questions . . . 10

5 TP 4 — Gouvernance, intégrité et confidentialité 11

5.1 Architecture et déroulement . . . 11

5.2 Catalogue, contrat et signature . . . 12

5.3 Calculs manuels du TP 4 . . . 12

5.3.1 Classification des journées . . . 12

5.3.2 Moyenne des admissions . . . 12

5.3.3 Seuil minimal et bruit de Laplace . . . 13

5.4 Tests négatifs de sécurité . . . 14

5.5 Captures des interfaces et résultats . . . 15

5.6 Réponses aux questions du TP 4 . . . 16

6 Synthèse comparative et conclusion générale 18

6.1 Du stockage fédéré à l'analyse fédérée . . . 18

6.2 En quoi le TP 4 améliore-t-il le TP 3 ? 18
6.3 Conclusion 19

Table des figures

2.1 Création et consultation séparée des bases environnementale et hospitalière. 4

3.1 Documentation Swagger de l'API environnementale (port 8001). 7
3.2 Documentation Swagger de l'API hospitalière (port 8002). 7
3.3 Exécution du client d'analyse et affichage des résultats. 7

4.1 Résultats agrégés calculés localement par l'organisation hospitalière. . 9

5.1 Architecture logique des trois nœuds du TP 4 : organisations, bases de données, API et échanges avec le laboratoire. 11
5.2 Exécution des trois tests négatifs : finalité non autorisée, clé incorrecte et signature falsifiée. 14
5.3 classifications des 10 jours et signature HMAC garantissant leur intégrité 15
5.4 Moyennes d'admissions calculées localement (sans bruit). 16
5.5 Résultats finaux : moyennes, seuil minimal et exécution avec bruit. . . 16

Résumé

Ce rapport présente la mise en place progressive d'un espace de données fédéré entre trois acteurs : une organisation environnementale, un établissement hospitalier et un laboratoire de recherche. À partir de données fictives relatives aux concentrations de PM2.5 et aux admissions respiratoires à Tanger, les quatre travaux pratiques explorent le stockage séparé, l'échange par API REST, le calcul local et les mécanismes de gouvernance et de confidentialité.

Résultat essentiel

Les données détaillées restent sous le contrôle de leur organisation propriétaire. Le laboratoire orchestre les échanges et exploite des résultats agrégés, tandis que le TP 4 ajoute des règles de finalité, un contrat, une signature HMAC, un seuil minimal de groupe et un mécanisme pédagogique de bruit.

Chapitre 1

Introduction générale

1.1 Contexte et problématique

Les organisations souhaitent valoriser leurs données conjointement sans nécessairement les transférer vers une base centrale. Dans le cas étudié, les mesures de qualité de l'air appartiennent à l'organisation environnementale, tandis que les admissions respiratoires appartiennent à l'hôpital. La question est donc de permettre une analyse commune tout en préservant le contrôle des données par leurs propriétaires.

1.2 Objectifs

— Créer et interroger deux bases de données indépendantes.
— Mettre en communication les organisations au moyen d'API REST.
— Déplacer le calcul vers les données lorsque cela est possible.
— Ajouter des mécanismes de gouvernance, d'intégrité et de protection statistique.
— Comparer les résultats et identifier les limites de chaque approche.

1.3 Jeu de données et hypothèses

Les données sont fictives et utilisées uniquement à des fins pédagogiques. Le seuil retenu pour identifier une journée de pollution élevée est strictement supérieur à 30 $\mu g/m^3$.

Qualité de l'air			Admissions hospitalières	
Date	**PM2.5**	**Catégorie**	**Date**	**Admissions**
01/10	12.0	Non élevée	01/10	8
02/10	35.5	Élevée	02/10	14
03/10	42.1	Élevée	03/10	18
04/10	15.2	Non élevée	04/10	9
05/10	38.0	Élevée	05/10	16
06/10	45.0	Élevée	06/10	20
07/10	22.1	Non élevée	07/10	10
08/10	18.0	Non élevée	08/10	7
09/10	31.0	Élevée	09/10	13
10/10	11.5	Non élevée	10/10	5

TABLE 1.1 – Jeu de données fictif du TP 4 (PM2.5 en $\mu g/m^3$)

Chapitre 2

TP 1 — Stockage fédéré et analyses locales

2.1 Principe et réalisation

Deux bases SQLite distinctes sont créées : `environnement.db`, qui contient la table `qualite_air(date, ville, pm25)`, et `hopital.db`, qui contient `admissions(date, ville, nombre)`. Chaque organisation conserve sa base et peut la consulter indépendamment.

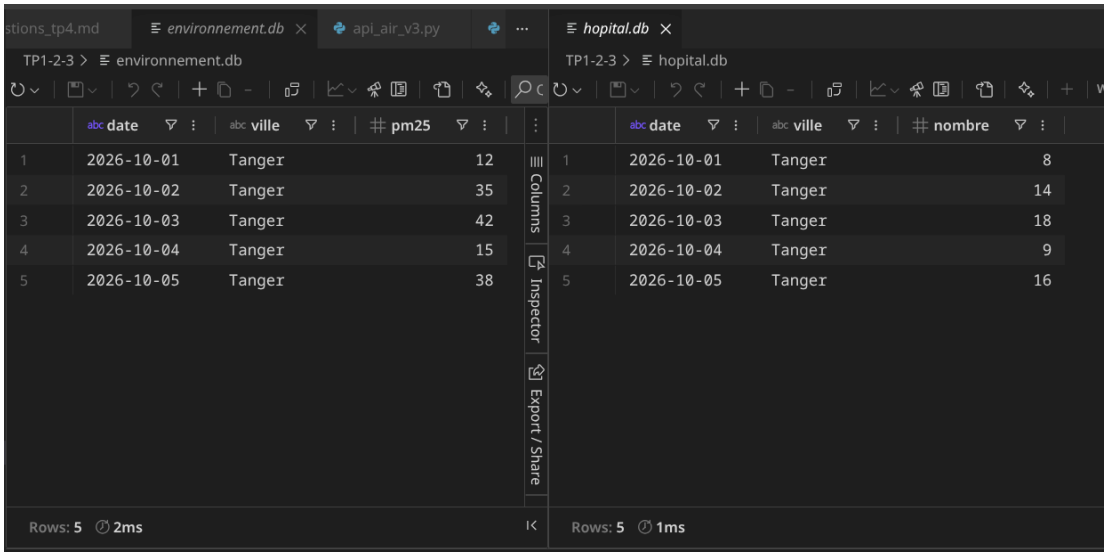


FIGURE 2.1 – Création et consultation séparée des bases environnementale et hospitalière.

2.2 Réponses aux questions

1. Où sont stockées les mesures de qualité de l'air ?

Elles sont stockées localement dans la base de données `environnement.db`, sous le contrôle de l'organisation environnementale.

2. **Où sont stockées les admissions hospitalières ?**
   Elles sont stockées localement dans la base de données `hopital.db`, sous le contrôle de l'hôpital.
3. **Les deux jeux de données sont-ils dans une même base ?**
   Non. Ils sont répartis dans deux bases SQLite indépendantes, ce qui permet à chaque organisation de conserver le contrôle de ses propres données.
4. **Comment le laboratoire peut-il découvrir les données disponibles sans centraliser les fichiers ?**
   Grâce à un catalogue de métadonnées qui décrit les jeux de données disponibles auprès de chaque organisation, sans transférer ni centraliser les bases de données.

Apport du TP 1

Le TP 1 met en place le principe du stockage fédéré : les données restent réparties entre les organisations, qui conservent chacune le contrôle de leur base locale. La découverte des données est possible sans centralisation.

Chapitre 3

TP 2 — Communication entre organisations avec API REST

3.1 Principe et réalisation

Chaque organisation expose ses données au moyen d'une API FastAPI indépendante. L'API environnementale fonctionne sur le port 8001 et l'API hospitalière sur le port 8002. Uvicorn exécute les serveurs et les interfaces Swagger sont accessibles via `/docs`. Un client Python interroge les deux API, associe les données par date et calcule les moyennes.

Composant	Rôle
FastAPI	Définir les routes REST et les réponses JSON.
Uvicorn	Exécuter les applications FastAPI.
API Air	Exposer les mesures et statistiques environnementales.
API Hôpital	Exposer les admissions et statistiques hospitalières.
Client d'analyse	Appeler les deux API, joindre les résultats et calculer les moyennes.

TABLE 3.1 – Composants du TP 2

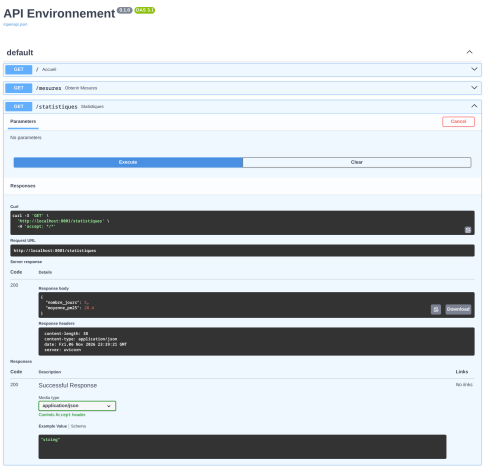


FIGURE 3.1 – Documentation Swagger de l'API environnementale (port 8001).

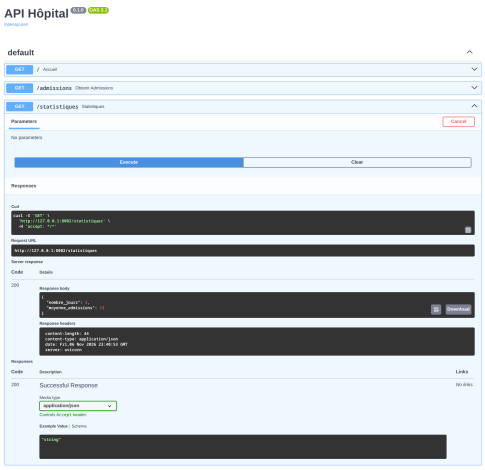


FIGURE 3.2 – Documentation Swagger de l'API hospitalière (port 8002).

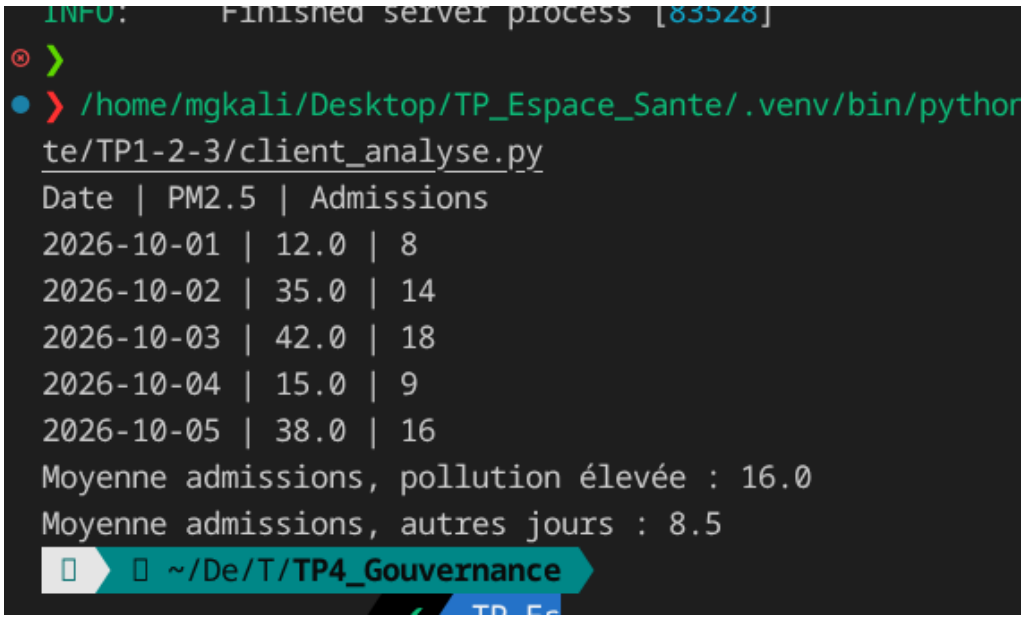


FIGURE 3.3 – Exécution du client d'analyse et affichage des résultats.

3.2 Résultats et réponses aux questions

Sur les cinq jours étudiés, les jours de pollution élevée (PM2.5 > 30 µg/m³) sont les 2, 3 et 5 octobre. Les admissions correspondantes sont 14, 18 et 16, soit une moyenne de 16 admissions par jour.

Pour les deux autres jours, les admissions sont 8 et 9, soit une moyenne de 8,5 admissions par jour.

1. **Quel est le rôle de FastAPI ?**
   FastAPI permet de créer des API REST et leurs points d'accès afin d'exposer les données des deux organisations.
2. **Quel est le rôle de Uvicorn ?**
   Uvicorn est le serveur qui exécute l'application FastAPI et permet aux clients de communiquer avec elle via HTTP.
3. **Pourquoi utilise-t-on deux ports différents ?**
   Les ports différents permettent d'exécuter simultanément les deux API sur une même machine, sans conflit : 8001 pour l'environnement et 8002 pour l'hôpital.
4. **Le laboratoire reçoit-il les données brutes ?**
   Oui. Dans cette version, le laboratoire récupère les données détaillées des deux API au format JSON et réalise lui-même les analyses.
5. **Une API REST garantit-elle automatiquement la confidentialité ?**
   Non. REST ne garantit pas à lui seul la confidentialité. Des mécanismes supplémentaires sont nécessaires, notamment l'authentification, l'autorisation et le chiffrement HTTPS.

Bilan du TP 2

Les deux organisations exposent leurs données à travers des API REST. Le laboratoire peut ainsi les récupérer et les analyser sans accéder directement aux bases de données. Cependant, les données brutes circulent encore entre les organisations, ce qui pose des limites en matière de confidentialité.

Limite identifiée

La communication est décentralisée, mais les données détaillées sont transférées au laboratoire. Le contrôle du stockage ne suffit donc pas à préserver la confidentialité des informations échangées.

Chapitre 4

TP 3 — Calcul local, contrôle d'accès et analyse fédérée

4.1 Principe et réalisation

Le TP 3 déplace une partie du traitement vers les organisations propriétaires. L'API environnementale transmet des dates et des catégories de pollution (`elevee` ou `non_elevee`) au lieu des valeurs PM2.5 exactes. L'API hospitalière reçoit ces classifications, calcule les statistiques directement à partir de sa base locale et renvoie uniquement des agrégats au laboratoire.

Les API sont protégées par des clés de démonstration. Cette authentification limite l'accès aux services, mais ne suffit pas à empêcher toutes les inférences statistiques.



FIGURE 4.1 – Résultats agrégés calculés localement par l'organisation hospitalière.

4.2 Résultats et réponses aux questions

Pour les cinq jours étudiés, la moyenne des admissions est de 16 pour les jours de pollution élevée et de 8,5 pour les autres jours. La différence est donc de 7,5 admissions par jour.

1. **Quelles données le laboratoire reçoit-il dans le TP 2 et dans le TP 3 ?**
   Dans le TP 2, le laboratoire reçoit les données brutes : les concentrations PM2.5 et les admissions hospitalières. Dans le TP 3, il reçoit uniquement les catégories de pollution et les statistiques agrégées.
2. **Pourquoi l'hôpital effectue-t-il les calculs dans son propre environnement ?**
   Pour conserver le contrôle de ses données et éviter de transférer les admissions individuelles au laboratoire.
3. **Quelles informations sont transmises à l'hôpital ?**
   Les dates et les catégories de pollution (`elevee` et `non_elevee`), transmises au format JSON.
4. **Une statistique agrégée garantit-elle toujours la confidentialité ?**
   Non. Une requête portant sur un seul jour peut révéler directement le nombre exact d'admissions de ce jour.
5. **Une clé API suffit-elle pour garantir la souveraineté des données ?**
   Non. Elle contrôle l'accès au service, mais ne garantit pas la souveraineté. Des règles d'utilisation, une gouvernance et une traçabilité sont également nécessaires.
6. **Comment limiter les demandes d'analyse aux opérations autorisées ?**
   En définissant les opérations autorisées, une taille minimale de groupe, des limites de requêtes et des règles d'accès.
7. **Quels composants supplémentaires faut-il pour un véritable espace de données ?**
   Un catalogue de données, une gestion des identités et des accès, des contrats d'utilisation, une traçabilité des échanges ainsi que des mécanismes de sécurité et de gouvernance.

Limite identifiée

Le calcul local réduit le transfert des données brutes, mais une requête trop ciblée peut encore divulguer une information individuelle. Le TP 4 introduit donc des mécanismes supplémentaires de gouvernance et de confidentialité.

Chapitre 5

TP 4 — Gouvernance, intégrité et confidentialité

5.1 Architecture et déroulement

Le TP 4 introduit trois nœuds distincts. Le nœud A publie le catalogue, vérifie la demande et signe les classifications. Le nœud B vérifie la signature, calcule localement les statistiques hospitalières et applique les règles de protection. Le nœud C, laboratoire, orchestre les échanges sans accéder directement aux bases.

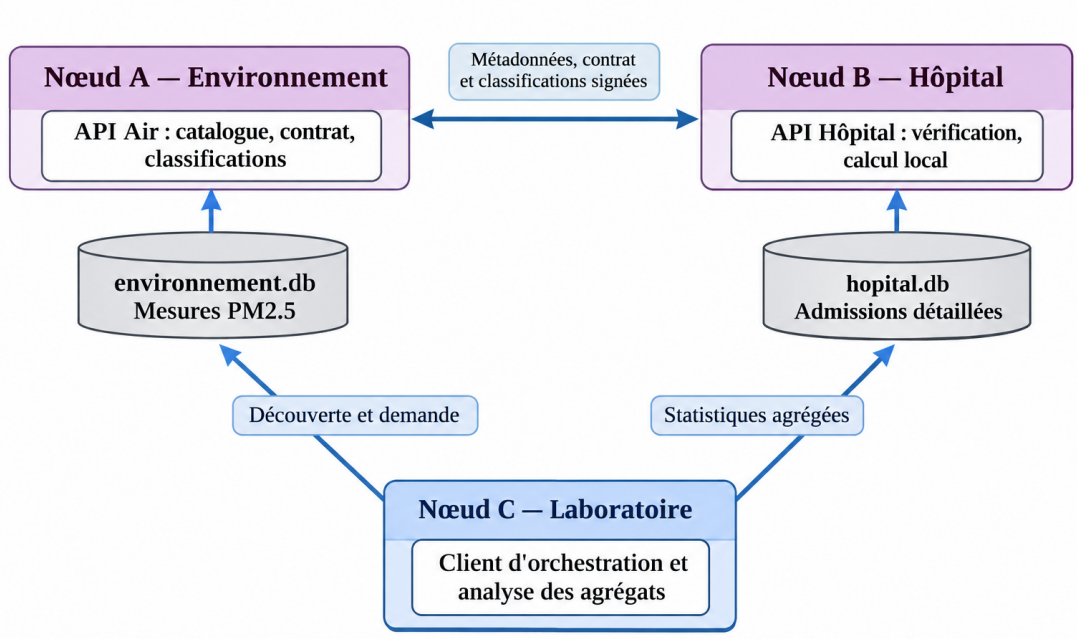


Figure 1 : Architecture logique des trois nœuds du TP 4

FIGURE 5.1 – Architecture logique des trois nœuds du TP 4 : organisations, bases de données, API et échanges avec le laboratoire.

5.2 Catalogue, contrat et signature

Le catalogue décrit le jeu de données à l'aide de métadonnées : identifiant, titre, description, éditeur, période couverte, unité, point d'accès et finalité autorisée. DCAT est un vocabulaire standard destiné à décrire les catalogues et jeux de données ; le catalogue du TP en reprend certains principes sans constituer une implémentation complète du standard.

La négociation crée un contrat associé à un identifiant, un consommateur, un jeu de données et une finalité. La finalité `research` est vérifiée avant l'accès. La signature HMAC-SHA256 permet au nœud B de vérifier que le paquet de classifications n'a pas été modifié depuis sa signature par le nœud A.

5.3 Calculs manuels du TP 4

5.3.1 Classification des journées

Avec le seuil strict $PM2.5 > 30$, cinq journées sont classées comme fortement polluées : 2, 3, 5, 6 et 9 octobre. Les cinq autres journées appartiennent au groupe de pollution non élevée.

5.3.2 Moyenne des admissions

Pour les jours de pollution élevée :

$$\bar{x}_{\text{leve}} = \frac{14 + 18 + 16 + 20 + 13}{5} = \frac{81}{5} = \boxed{16,2}$$

Pour les jours de pollution non élevée :

$$\bar{x}_{\text{non leve}} = \frac{8 + 9 + 10 + 7 + 5}{5} = \frac{39}{5} = \boxed{7,8}$$

La différence entre les deux moyennes est :

$$\Delta = 16,2 - 7,8 = \boxed{8,4 \text{ admissions/jour}}$$

Interprétation

Sur ce jeu fictif, les jours classés comme fortement pollués présentent une moyenne d'admissions supérieure de 8,4 admissions par jour. Cette différence indique une association dans les données ; elle ne démontre pas une relation de causalité.

5.3.3 Seuil minimal et bruit de Laplace

Le nœud hospitalier impose un seuil minimal de trois jours. Un groupe contenant moins de trois jours est supprimé afin de limiter les risques de divulgation par requête trop ciblée. Ce seuil est une règle de prudence, pas une preuve de k-anonymat.

Lorsque le bruit différentiel est activé, le code utilise une échelle de bruit de la forme :

$$b = \frac{\text{sensibilité}}{\varepsilon} \qquad \text{avec} \qquad \text{sensibilité} = \frac{30}{n}$$

d'où :

$$\boxed{b = \frac{30}{n\varepsilon}}$$

où n est le nombre de jours du groupe et ε le paramètre de confidentialité. Une valeur plus faible de ε produit généralement davantage de bruit et une meilleure protection, mais réduit la précision.

Mode	Résultat attendu	Interprétation
Sans bruit	Moyennes exactes : 16,2 et 7,8	Résultats fidèles aux données du TP, mais davantage exposés aux inférences.
Avec bruit	Moyennes perturbées aléatoirement	Protection accrue, mais les valeurs peuvent s'éloigner des moyennes exactes.

TABLE 5.1 – Comparaison qualitative des résultats avec et sans bruit

Valeurs observées lors de l'exécution : (les valeurs changes dans chaque execution)

— Moyenne bruitée du groupe élevé : 18.81

— Moyenne bruitée du groupe non élevé : 9.72

— Valeur de ε utilisée : 1.0

Le programme constitue une démonstration pédagogique et non une implémentation complète de confidentialité différentielle. La garantie formelle dépend notamment de la définition rigoureuse de la sensibilité, du mécanisme appliqué, de la composition des requêtes et d'une gestion fiable du budget de confidentialité. Le budget et les contrats conservés uniquement en mémoire ne constituent pas un mécanisme de production robuste.

5.4 Tests négatifs de sécurité

Les trois tests suivants permettent de vérifier le contrôle d'accès et l'intégrité des échanges. Les captures doivent montrer la requête envoyée ainsi que le code HTTP effectivement retourné.

Test	Manipulation	Résultat attendu	Contrôle vérifié
Finalité non autorisée	Demander un contrat avec une finalité autre que `research`.	HTTP 403	Refus d'un usage non autorisé.
Clé incorrecte	Appeler une route protégée avec une clé API erronée.	HTTP 401	Refus d'un client non authentifié.
Signature falsifiée	Modifier une classification après signature et envoyer le paquet à B.	HTTP 403	Détection de l'altération par HMAC.

TABLE 5.2 – Tests négatifs réalisés sur le TP 4

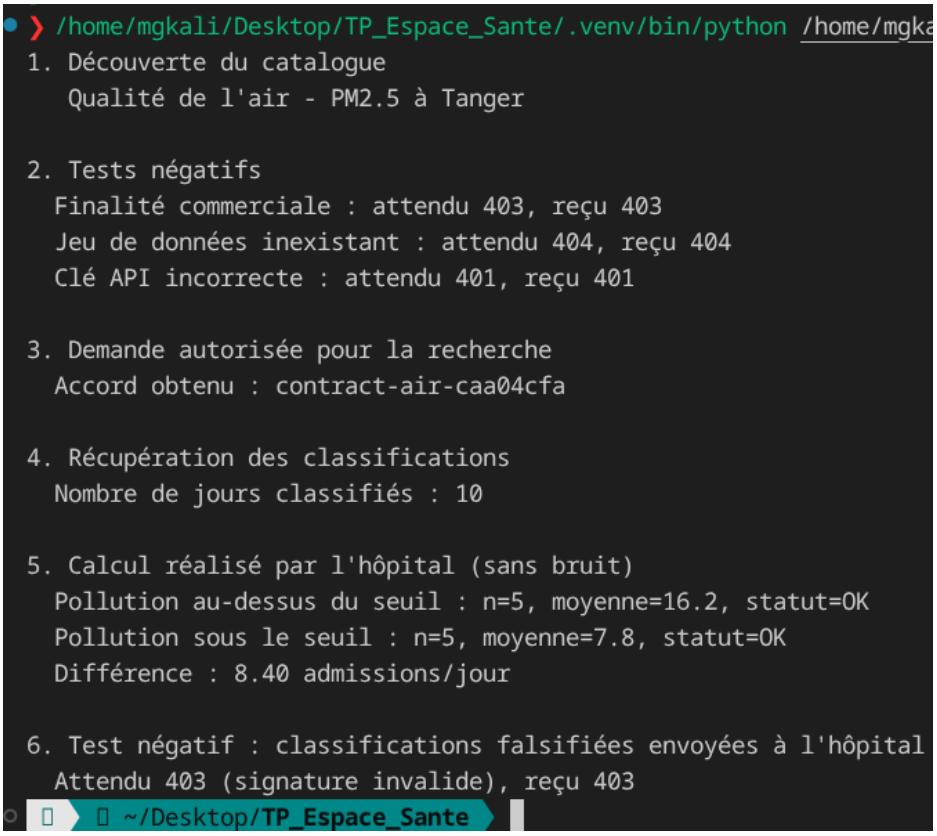


FIGURE 5.2 – Exécution des trois tests négatifs : finalité non autorisée, clé incorrecte et signature falsifiée.

5.5 Captures des interfaces et résultats

Les captures ci-dessous doivent provenir de l'exécution réelle du TP 4. Elles servent à démontrer la disponibilité des API, la négociation du contrat et le résultat de l'analyse.



FIGURE 5.3 – classifications des 10 jours et signature HMAC garantissant leur intégrité

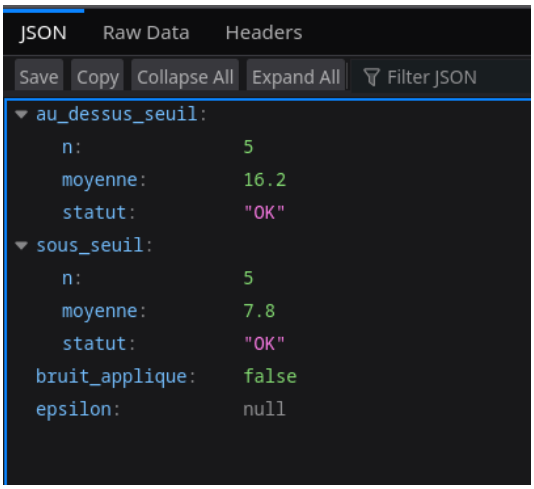


FIGURE 5.4 – Moyennes d'admissions calculées localement (sans bruit).

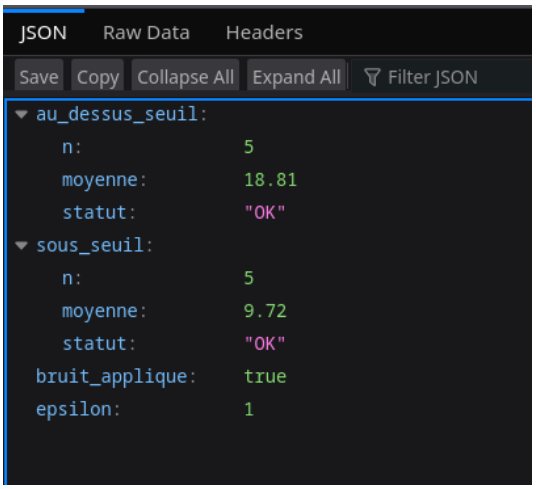


FIGURE 5.5 – Résultats finaux : moyennes, seuil minimal et exécution avec bruit.

5.6 Réponses aux questions du TP 4

1. **Quelles informations permettent au laboratoire de découvrir le jeu de données ?**
   Les métadonnées du catalogue : identifiant, titre, description, organisation propriétaire, période couverte, unité de mesure et conditions d'accès.
2. **Qu'est-ce que DCAT ?**
   DCAT est un vocabulaire standard permettant de décrire et de découvrir les jeux de données. Le catalogue du TP est une version simplifiée inspirée de ce standard.
3. **Pourquoi contrôler la finalité avant d'autoriser l'accès ? Quelle est la différence entre catalogue, politique d'usage et contrôle d'accès ?**
   Le contrôle de la finalité permet de vérifier que les données sont utilisées pour un objectif autorisé.
   — **Catalogue :** décrit les données disponibles.
   — **Politique d'usage :** définit les conditions d'utilisation.
   — **Contrôle d'accès :** autorise ou refuse les demandes selon les règles établies.
4. **Quelles informations circulent entre les nœuds ? Pourquoi la conservation locale ne suffit-elle pas à garantir la confidentialité ?**
   Les métadonnées, demandes de contrat, classifications signées et statistiques agrégées circulent entre les nœuds. Les admissions détaillées restent dans la base hospitalière. Cependant, les informations transmises peuvent encore permettre certaines

inférences.

5. **Pourquoi supprimer les statistiques des petits groupes ? Le seuil de trois jours garantit-il le k-anonymat ?**
   La suppression limite la divulgation d'informations sensibles. Toutefois, un seuil de trois jours ne garantit pas le k-anonymat. La signature HMAC permet de détecter toute modification des classifications après leur signature.
6. **Quel est le compromis entre précision et protection avec et sans bruit ?**
   Sans bruit, les résultats sont exacts, mais peuvent révéler davantage d'informations. Avec bruit, la protection augmente au détriment de la précision. L'implémentation reste pédagogique : la sensibilité, la composition et le budget de confidentialité ne bénéficient pas de toutes les garanties d'une implémentation formelle.
7. **La différence observée prouve-t-elle que la pollution provoque les admissions ?**
   Non. Une corrélation ne prouve pas une causalité. Il faudrait également considérer la température, l'humidité, l'âge, le tabagisme, les maladies préexistantes et les infections respiratoires, ainsi qu'étudier une période plus longue.

Chapitre 6

Synthèse comparative et conclusion générale

6.1 Du stockage fédéré à l'analyse fédérée

Les quatre TP représentent des niveaux complémentaires, qui ne doivent pas être confondus.

Notion	Signification	Mise en œuvre dans les TP
Stockage fédéré	Les données restent dans les systèmes des organisations propriétaires.	TP 1 : deux bases SQLite séparées.
Traitement fédéré	Les traitements sont exécutés au plus près des données, sans transférer systématiquement les données brutes.	TP 3 et TP 4 : calcul des statistiques dans la base hospitalière.
Analyse fédérée	Plusieurs sources contribuent à une analyse commune par échange de résultats, de classifications ou d'agrégats.	TP 2 à TP 4 : rapprochement des informations air/hôpital et comparaison des groupes.

TABLE 6.1 – Distinction entre stockage, traitement et analyse fédérés

6.2 En quoi le TP 4 améliore-t-il le TP 3 ?

Le TP 3 avait déjà introduit le calcul local et les clés API, mais une requête ciblée pouvait encore révéler une valeur individuelle. Le TP 4 ajoute plusieurs protections complémentaires :

— un catalogue pour découvrir les jeux de données sans accéder directement aux

bases ;
— une négociation de contrat et un contrôle de la finalité ;
— une signature HMAC pour vérifier l'intégrité des classifications transmises ;
— un seuil minimal de taille de groupe pour bloquer certaines requêtes trop précises ;
— un mécanisme de bruit et un budget de confidentialité à titre pédagogique.

6.3 Conclusion

Cette série de travaux pratiques montre qu'un espace de données fédéré ne se limite pas à connecter plusieurs bases. Il faut également organiser les échanges, déplacer les calculs vers les données lorsque cela est pertinent et définir des règles de gouvernance vérifiables. Le TP 4 corrige plusieurs limites du TP 3 en ajoutant des contrats, un contrôle de finalité, une vérification d'intégrité et des protections statistiques.

Ces mécanismes réduisent les risques, mais ne garantissent pas à eux seuls une confidentialité absolue. En particulier, le seuil de trois jours n'est pas une preuve de k-anonymat et la simulation de bruit ne constitue pas une garantie complète de confidentialité différentielle. Enfin, les résultats statistiques observés décrivent une association sur un jeu fictif et limité ; ils ne permettent pas de conclure à un lien causal entre pollution et admissions hospitalières.